# Caracterización mecánica de tejidos fibrados mediante *machine learning*

**Elías Núñez-Ortega[1], Pablo Blázquez-Carmona[2], Marta Montón-Padilla[2], José A. Sanz-Herrera[1], Esther Reina-Romo[1]**

[1] *Escuela Técnica Superior de Ingeniería, Universidad de Sevilla, España, enunez3@us.es.*

[2] *Escuela Superior de Ingeniería, Universidad de Cádiz, España.*

## Introducción

El comportamiento mecánico de los tejidos biológicos depende de su microestructura de fibras [1], siendo relevante en el estudio de la mecanobiología celular [2]. Sin embargo, su caracterización experimental presenta diversas limitaciones [3], mientras que los modelos detallados *in silico* pueden requerir un elevado coste computacional. En este trabajo se propone una metodología predictiva basada en datos, empleando simulaciones de una red interconectada de fibras de colágeno obtenidas mediante un modelo validado previamente. A partir de las respuestas obtenidas se desarrollan modelos estadísticos y de *machine learning* para predecir su comportamiento mecánico.

## Metodología

La red de fibras se simula mediante el modelo discreto desarrollado en [4], generando una red de fibras compuesta por 882 fibras, siendo 442 fibras de entrecruzamiento. La geometría de las fibras se caracteriza mediante una tortuosidad del 15% y una longitud entre extremos de [4].

La respuesta mecánica macroscópica en ensayos de tracción, compresión y cizallamiento simple se obtiene mediante la formulación multiescala propuesta en [4], considerando módulos elásticos de fibras () en el rango y diámetros de fibra () en el rango .

A partir de las simulaciones, se desarrollan modelos predictivos para estimar las respuestas mecánicas. Se emplean métodos de interpolación lineal y logarítmica, y los modelos de *machine learning* "*Regression Ensemble*", "*Support Vector Regression*" y "*Gaussian Process Regression*". Los parámetros y se utilizan como entradas para predecir la respuesta mecánica.

La validación de los modelos se realiza mediante la estrategia *leave-one-out*, excluyendo un caso completo en cada iteración para entrenar el modelo con las simulaciones restantes y posteriormente predecir la respuesta del caso excluido. La precisión se evalúa mediante el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error relativo.

## Resultados

La Figura 1 muestra la respuesta mecánica simulada y las predicciones obtenidas para uno de los casos bajo cizallamiento simple. El modelo "*Gaussian Process Regression*" (GPR) proporciona la predicción más precisa, reproduciendo con mayor fidelidad la respuesta que el resto de los métodos. Esta tendencia se mantiene para todas las combinaciones de y y en los tres tipos de ensayo (tracción, compresión y cizallamiento simple). Además, la Tabla 1 recoge las métricas de error obtenidas mediante GPR para los casos analizados.

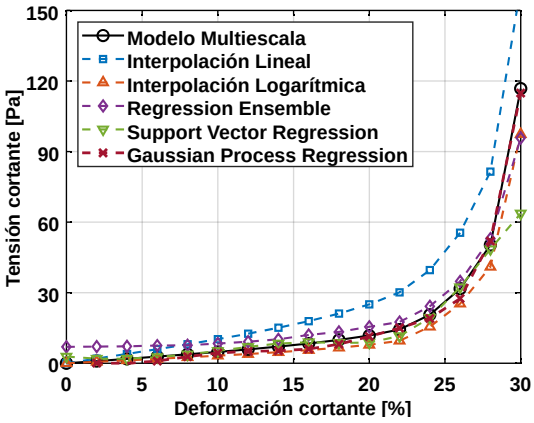



*Figura 1: Respuesta mecánica de la red de fibras obtenida mediante la formulación multiescala vs. respuestas predichas mediante los métodos de interpolación y machine learning bajo un ensayo de cizallamiento simple, para y .*

| Ensayo | | | |
|---|---|---|---|
| Tracción | 0.22 | 0.27 | 0.06 |
| Compresión | 0.04 | 0.05 | 0.05 |
| Cizallamiento | 1.79 | 2.20 | 0.39 |

*Tabla 1: Métricas de error globales para los ensayos de tracción, compresión y cizallamiento simple mediante el modelo de machine learning "Gaussian Process Regression".*

## Conclusiones

El modelo de *machine learning* GPR reproduce el comportamiento mecánico no lineal de la red de fibras con un error relativo inferior al 0.40%, empleando solo 29 simulaciones para su entrenamiento y validación. Además, permite predecir la respuesta en tiempos inferiores al minuto, frente a las horas o días requeridos por las simulaciones, lo que lo convierte en una potencial alternativa al modelado tradicional.

## Agradecimientos

Proyecto PID2024-161310NB-I00 financiado por MICIU/AEI /10.13039/501100011033 y por FEDER, UE.

Ayuda PREP2023-001306 financiada por MICIU/AEI /10.13039/501100011033 y por el FSE+.

## Referencias

[1] Sherman et al, J Mech Behav Biomed Mater, 52:22-50, 2015.
[2] Saraswathibhatla et al, Nat Rev Mol Cell Biol, 24:495-516, 2023.
[3] Bose et al, Materials, 15:2753, 2022.
[4] Sanz-Herrera et al, Comput Struct, 310:107690, 2025.